

# Clasificación Binaria de Ritmo Cardíaco (Normal vs. AFib) a partir de Estadísticas de Intervalos RR

Diego Salvador  
dsalvador21@alumnos.utalca.cl

## Resumen

Se presenta un modelo de Machine Learning para clasificar ritmos cardíacos como normales o fibrilación auricular (AFib), utilizando características estadísticas del intervalo RR derivadas de señales ECG reales. Se describe el contexto clínico, el problema abordado, la propuesta de solución y los resultados experimentales obtenidos.

## 1. Contexto

La fibrilación auricular (AF) es la arritmia sostenida más común y se manifiesta en el ECG por la ausencia de ondas P bien definidas y una marcada irregularidad en los intervalos RR. Su detección oportuna es esencial, ya que se asocia a un mayor riesgo de accidente cerebrovascular, insuficiencia cardíaca y mortalidad.

Con el fin de fomentar el desarrollo de soluciones automáticas, el PhysioNet/CinC Challenge 2017 propuso un desafío orientado a clasificar grabaciones cortas de ECG de una sola derivación en cuatro clases: ritmo normal (N), fibrilación auricular (A), otros ritmos (O) y señales ruidosas (~). Estas señales fueron obtenidas en condiciones reales con dispositivos portátiles, lo que introduce ruido, artefactos de movimiento y gran variabilidad entre pacientes.

El conjunto de entrenamiento incluye 8.528 señales con duraciones entre 9 y 61 segundos, y una frecuencia de muestreo de 300 Hz. Una

característica clave para identificar AF es la variabilidad de los intervalos RR, que tienden a ser altamente irregulares en esta condición.

## 2. Problema

Este trabajo aborda un subconjunto del desafío propuesto en el PhysioNet/CinC Challenge 2017. Específicamente, se enfoca únicamente en la detección binaria entre ritmo normal (N) y fibrilación auricular (A). Esta simplificación tiene fines educativos y busca evaluar la efectividad de algoritmos básicos de aprendizaje automático al trabajar con características estadísticas simples derivadas del intervalo RR.

## 3. Propuesta de solución

Se propone un pipeline de clasificación supervisada utilizando un modelo básico de Machine Learning, específicamente, Random Forest, en-

trenado con cuatro características estadísticas: media, desviación estándar, asimetría y curtosis del intervalo RR. El objetivo es lograr un buen rendimiento en la clasificación binaria (N vs A) sin recurrir a técnicas complejas, demostrando la utilidad de enfoques simples en tareas clínicas reales.

Random Forest es una opción adecuada para este problema, ya que maneja relaciones no lineales entre variables sin requerir transformaciones previas, es robusto frente a ruido y valores atípicos —comunes en señales fisiológicas— y permite evaluar la importancia relativa de las características, lo cual aporta interpretabilidad y guía para futuras mejoras.

## 4. Metodología

El proceso seguido para abordar este trabajo se dividió en tres etapas principales:

### 4.1 Obtención y preparación de los datos

Los datos fueron obtenidos desde la página oficial de PhysioNet, descargando el archivo **training2017.zip**. Este contenía tres tipos de archivos por cada señal:

- **.mat**: archivo que almacena la señal ECG como un arreglo numérico.
- **.hea**: encabezado con metadatos como frecuencia de muestreo (300 Hz), factor de conversión y unidad fisiológica.
- **REFERENCE.csv**: archivo con etiquetas clínicas asignadas por expertos.

Se utilizó Python y librerías como **wfdb**, **scipy.io** y **pandas** para convertir los archivos

y analizarlos. Se identificó que el dataset contenía un total de 8528 señales, con una duración entre 9 y 61 segundos, y las siguientes clases:

- N (Normal): 5050 registros
- O (Otros ritmos): 2456 registros
- A (AFib): 738 registros
- (Ruido): 284 registros

Se filtraron las señales con etiquetas N y A, y se utilizaron las funciones de **neurokit2** para detectar picos R y calcular los intervalos RR de cada señal. Posteriormente, se calcularon las siguientes estadísticas sobre cada señal: media (**mean\_rr**), desviación estándar (**std\_rr**), asimetría (**skew\_rr**) y curtosis (**kurt\_rr**). Los registros con menos de 10 picos R fueron descartados, ya que no permitían un análisis estadístico confiable.

### 4.2 Análisis exploratorio

Se realizó un análisis estadístico y gráfico de las características, observando diferencias claras entre clases:

- **mean\_rr**: menor en casos de AFib, consistente con ritmos más acelerados.
- **std\_rr**: mayor en casos de AFib, indicando mayor variabilidad.
- **skew\_rr**: mayor en AFib. La asimetría refleja colas largas hacia un lado, posiblemente por latidos más irregulares.
- **kurt\_rr**: similar en ambas clases.

Se identificaron valores atípicos en algunas variables, tanto en registros normales como con AFib, lo que motivó un tratamiento posterior de outliers.

### 4.3 Construcción y entrenamiento del modelo

Los registros fueron separados por clase y se aplicó eliminación de outliers basada en el rango intercuartílico (IQR), con un parámetro de 2.0 para tolerar valores extremos típicos de arritmias.

Luego, los datos fueron reunidos y divididos en conjunto de entrenamiento (80%) y prueba (20%) con partición estratificada. Dado el desbalanceo de clases, se aplicó SMOTE para sobre-muestrear la clase A (AFib).

Se entrenó el modelo, aplicando búsqueda de hiperparámetros mediante GridSearchCV con validación cruzada. Finalmente, se evaluó el rendimiento del modelo mediante matriz de confusión y métricas estándar (precision, recall, F1-score), enfocándose especialmente en mejorar la clasificación de la clase minoritaria A.

## 5. Resultados experimentales

Los mejores parámetros obtenidos fueron:

- `n_estimators`: 200
- `max_depth`: 20
- `min_samples_split`: 2
- `min_samples_leaf`: 1
- `class_weight`: 'balanced'

El modelo fue evaluado sobre un conjunto de prueba de 1046 registros balanceado entre clases. En la tabl, se presentan las métricas por clase, así como los promedios macro y ponderado (weighted).

Clase	Precision	Recall	F1-Score	Soporte
A (AFib)	0.86	0.86	0.86	133
N (Normal)	0.98	0.98	0.98	913
<b>Macro avg</b>	0.92	0.92	0.92	1046
<b>Weighted avg</b>	0.97	0.97	0.97	1046
<b>Accuracy</b>	<b>0.97</b>			

En la figura 1 se observa la matriz de confusión del modelo. La mayoría de los errores de clasificación se concentran en confundir AFib como ritmo normal, lo que representa un punto a mejorar clínicamente.




Figura 1: Matriz de confusión del modelo optimizado.

Por otro lado, la figura 2 muestra la importancia media de las variables estadísticas usadas. La desviación estándar del RR (`std_rr`) y la asimetría (`skew_rr`) fueron las más relevantes para la clasificación, seguidas de la media y la curtosis.




Figura 2: Importancia de características según el modelo Random Forest.

## 6. Impacto

Este trabajo demuestra que, incluso con características simples derivadas de los intervalos RR de señales ECG, es posible construir un clasificador eficaz capaz de distinguir entre ritmo sinusal normal y fibrilación auricular con relativa precisión. La estrategia empleada —basada en aprendizaje supervisado con algoritmos clásicos— permite detectar patrones clínicamente relevantes de forma automatizada.

Si bien el presente enfoque simplifica el problema real al limitarse a dos clases y a un conjunto de señales curadas, constituye un punto de partida valioso hacia el desarrollo de herramientas de apoyo diagnóstico. Su bajo costo computacional lo hace especialmente prometedor para su futura implementación en dispositivos portátiles o sistemas de monitoreo continuo.

No obstante, su uso en un entorno clínico real requeriría validaciones más exhaustivas, incorporación de más clases, manejo robusto del ruido,

y evaluaciones sobre datos más diversos y no curados.

## Referencias

- Clifford GD, Liu CY, Moody B, Lehman L, Silva I, Li Q, Mark RG. *AF Classification from a Short Single Lead ECG Recording: The PhysioNet/Computing in Cardiology Challenge 2017*. Computing in Cardiology, vol. 44, 2017. Disponible en: <https://physionet.org/content/challenge-2017/1.0.0/>